

Análise de dados ENEM para as edições de 2022, 2023 e 2024

José Danilo Martins Vieira, Marcos Felipe de Souza Pedreira e Nicolas Zafred Paiva

1. INTRODUÇÃO

O Exame Nacional do Ensino Médio (ENEM) é uma avaliação aplicada anualmente com o objetivo de medir o desempenho dos estudantes do ensino médio e servir como critério para acesso ao ensino superior no Brasil. A análise dos dados do ENEM permite identificar padrões de desempenho, tendências ao longo dos anos e possíveis áreas de melhoria na educação.

O presente projeto tem como objetivo analisar os dados das edições de 2022, 2023 e 2024 do ENEM, investigando aspectos relevantes como notas médias, distribuição de desempenho entre regiões e correlações entre diferentes áreas de conhecimento. A partir dessa análise, pretende-se gerar informações que contribuam para a compreensão do desempenho dos estudantes brasileiros e subsidiem futuras estratégias educacionais.

2. MATERIAIS E MÉTODOS

Os dados utilizados neste estudo correspondem às edições de 2022, 2023 e 2024 do Exame Nacional do Ensino Médio (ENEM), disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) em seu portal oficial. Foram coletadas informações sobre notas dos participantes, respostas do questionário socioeconômico, distribuição por estados e regiões, além de variáveis relacionadas ao desempenho por área do conhecimento.

O tratamento e a análise estatística dos dados foram realizados utilizando o software R, juntamente com as bibliotecas do “Tidyverse”, e os pacotes “geobr” e “sf” para a análise de estatística espacial. A coleta dos dados foi feita com o auxílio da função “read.csv2()”, e em seguida realizamos a transformação das colunas das notas com a função “as.double()” a fim de transformá-las em variáveis de tipo numérico. Em seguida, foram aplicadas técnicas descritivas, como cálculo de médias, medianas e desvio padrão, para caracterizar o desempenho dos participantes em cada edição do exame.

Neste trabalho iremos utilizar o coeficiente de correlação linear de Pearson (eq. 1), bem como o modelo de regressão linear calculado pela função “lm()” do R. Tanto este coeficiente com o

modelo de regressão baseia-se na premissa de que a linearidade é adequada para explicar a relação entre as variáveis analisadas, isto não é necessariamente verdade, mas é válido como uma primeira abordagem de análise.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n - 1)S_x S_y} \quad (1)$$


Para visualização e interpretação dos resultados, foram gerados gráficos e figuras, incluindo histogramas, boxplots e gráficos de dispersão, permitindo observar a distribuição de notas, identificar tendências ao longo dos anos e comparar o desempenho entre regiões e áreas de conhecimento. Todos os gráficos apresentados neste relatório foram produzidos diretamente no R, garantindo consistência e precisão nas análises.

3. RESULTADOS

Após a coleta da base de dados, realizamos a análise da distribuição das notas de todos os candidatos participantes do Enem de 2024. A figura abaixo resume essa análise, mostrando o boxplot das notas, o histograma e o ajuste com uma função normal gaussiana das notas. O terceiro gráfico consiste em um teste para avaliar se a distribuição realmente pode ser considerada normal a partir do cálculo do coeficiente de determinação.

A partir dele podemos afirmar que a distribuição de notas para o Enem 2024 pode ser descrita por uma curva normal, assim confirmado pelo teorema do limite central. É importante destacar aqui que o mesmo comportamento foi identificado para as três edições do ENEM selecionadas. Optamos por representar apenas os resultados para uma edição, de modo a evitar poluição do relatório, porém caso seja necessário confirmar, basta substituir os comandos no programa R, trocando para os dados das edições desejadas.

Gráfico 1, 2 e 3 – Boxplot, Histograma e QQ-plot das notas ENEM 2024



Os coeficientes de correlação para as três edições do ENEM estudadas também foram calculados, conforme mostra a tabela a seguir.

Tabela 1 – Coeficientes de correlação para as edições ENEM 2022, 2023 e 2024


Ano	R^2
2022	0,9983511
2023	0,9983809
2024	0,9974326

A nota final de cada participante do Enem é formulada pela média simples de cinco notas de cada área de conhecimento testada, são elas: ciências da natureza, ciências humanas, linguagens e códigos, matemática e redação. Como cada área é testada em segmentos separados da avaliação, é interessante analisar a possível relação que cada nota tem com as demais áreas de conhecimento.

Para isto utilizaremos o gráfico de matriz de correlação, em que são analisadas as relações entre as notas de cada área de conhecimento aplicada no exame do ENEM na edição de 2024. As diagonais apresentam as distribuições de probabilidade das notas para cada prova objetiva e a redação.

É interessante notar como a distribuição das notas de matemática apresenta uma certa bimodalidade, com um dos picos com maior probabilidade se concentrando em uma nota inferior ao outro pico, com uma nota mais elevada, porém com densidade de probabilidade menor. A distribuição das notas de redação apresenta a mesma bimodalidade das notas de matemática, mas com um certo ruído oscilatório. Talvez isso ocorra em função dos critérios de avaliação empregados nos textos dissertativos. O mesmo comportamento se aplica para as edições de 2022 e 2023.

Gráfico 4 – Matriz de correlação entre as áreas de conhecimento do ENEM 2024



Os gráficos abaixo da diagonal são de dispersão para cada par de área de conhecimento. Como o número de candidatos está na ordem de alguns milhões, estes gráficos foram feitos com um conjunto amostral do total de notas através da função “sample_frac” coletando 1% das notas.

Por último, temos os dados da parte superior a diagonal, estes são os coeficientes de correlação de Pearson (aqui a função “sample_frac” não foi usada, logo o coeficiente foi obtido com base na totalidade dos dados). O maior índice de correlação foi obtido entre as disciplinas de linguagens e códigos e ciências humanas, ao passo que a menor correlação linear obtida se deu entre ciências da natureza e redação. Essa tendência é corroborada pelos dados de 2023 e 2022, e isso faz sentido a se observarmos as competências e habilidades testadas em cada uma das provas, isto é, áreas que requerem capacidades semelhantes deveram ter resultados semelhantes, assim como áreas distintas terão notas dispares.

No intuito de avaliar os possíveis fatores que impactam na nota final de um participante do Enem, realizamos uma regressão linear múltipla usando a função “lm()” do R, tendo como as variáveis explicativas as respostas do questionário socioeconômico e dados das escolas dos candidatos. A variável a ser explicada é a nota final, calculada como a média simples das cinco áreas de conhecimento avaliadas no exame. O modelo obtido resultou em um valor p que indica significância estatística ($< 5\%$), com um coeficiente de determinação igual a 0,3958, conforme mostrado na Figura 1 abaixo.

Figura 1 - Estatística do modelo aplicado aos dados do ENEM

```
Residual standard error: 70.27 on 537709 degrees of freedom  
(1806997 observations deleted due to missingness)  
Multiple R-squared:  0.3958,    Adjusted R-squared:  0.3956  
F-statistic:  3036 on 116 and 537709 DF,  p-value: < 2.2e-16
```

O modelo criado foi analisado com o auxílio da função “anova ()”, conforme mostra a Figura 2. A partir dele podemos ver que todas as variáveis categóricas analisadas são estatisticamente significativas para o modelo, pois os valores p estão na ordem de 10^{-16} . Observando apenas o parâmetro “Sum Sq”, que mede o grau de variação da variável dependente causada por cada categoria, vê-se que as duas variáveis mais relevantes são a dependência administrativa (Federal, Estadual, Municipal e Privada) e o estado brasileiro no qual a escola do candidato se localiza. Por outro lado, as variáveis com menor impacto na nota final do modelo seriam a ocupação da mãe (variável categórica dividida em 5 grupos de trabalho genericamente relacionados a setores da economia) e o sexo (Masculino ou Feminino).

Ressalvas precisam ser feitas sobre estes resultados: o modelo não leva em conta todas as informações disponíveis sobre os candidatos, já que escolhemos as variáveis explicativas com base na intuição de que elas seriam relevantes para o modelo; em segundo lugar, excluímos do modelo todos os candidatos que apresentaram alguma nota faltante dentro das quatro provas objetivas e a redação; por último, a aplicação deste modelo nos dados do exame de 2023 não foram bem sucedidos, pois o modelo só foi capaz de prever 20,6% das notas do total de participantes, e destas, conseguiu obter um índice de determinação igual a 86,24%. Isto talvez tenha ocorrido em razão de dados faltantes no questionário, o que faz o modelo devolver “NA” para a nota final do candidato.

Figura 2 – Modelo criado no R com a função “anova”

```
Analysis of Variance Table


Response: nota_final
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
estado_escola	26	273133136	10505121	2127.658	< 2.2e-16	***
peessoas_na_residencia	19	41757924	2197785	445.129	< 2.2e-16	***
dependencia_adm	3	965697563	321899188	65195.943	< 2.2e-16	***
localizacao_escola	1	10488891	10488891	2124.370	< 2.2e-16	***
faixa_etaria	19	112531261	5922698	1199.555	< 2.2e-16	***
sexo	1	1726455	1726455	349.668	< 2.2e-16	***
cor_raca	5	55933732	11186746	2265.711	< 2.2e-16	***
tipo_escola	1	10050301	10050301	2035.541	< 2.2e-16	***
renda_familiar_mensal	16	184330758	11520672	2333.343	< 2.2e-16	***
escolaridade_pai	6	30988327	5164721	1046.038	< 2.2e-16	***
escolaridade_mae	6	12371776	2061963	417.620	< 2.2e-16	***
ocupacao_pai	4	8741395	2185349	442.610	< 2.2e-16	***
ocupacao_mae	4	1074513	268628	54.407	< 2.2e-16	***
possui_computador	4	27899497	6974874	1412.658	< 2.2e-16	***
possui_internet	1	2115075	2115075	428.377	< 2.2e-16	***
Residuals	537709	2654890526	4937			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1						

O Gráfico 5 é o resultado da função “vip()” aplicada no modelo de regressão múltipla obtido. Essa função faz uma classificação da importância de cada uma das variáveis analisadas. Assim, levando essa classificação em conta, tem-se que a dependência administrativa do tipo estadual é a mais relevante para a determinação da nota de um candidato, o que corrobora com a análise feita pela função anova.


Gráfico 5 - Aplicação da função “vip()” no modelo de regressão múltipla



O gráfico 6 a seguir mostra a nota média de cada município do Brasil para o Enem 2024. A verificação da correlação espacial é feita pelo índice de Moran's global juntamente com o seu valor p. O resultado da análise permite rejeitar a hipótese nula de aleatoriedade espacial. Como o índice de Moran obtido é positivo, tem-se que os municípios com maior nota no Enem tendem a estar cercados por outros municípios de nota elevada, a recíproca é verdadeira. O mesmo resultado geral pode ser verificado se inserido os dados dos anos 2022 e 2023.

É importante destacar que dez municípios não tinham participantes e assim as suas notas foram substituídas pela mediana nacional.

Gráfico 6 – Nota média do ENEM 2024 por município brasileiro



4. CONCLUSÃO

A análise dos dados do ENEM referentes às edições de 2022, 2023 e 2024 permitiu identificar padrões consistentes no desempenho dos participantes, bem como compreender melhor os fatores associados às notas obtidas no exame. Os resultados indicaram que a distribuição das notas pode ser adequadamente descrita por uma distribuição normal nas três edições analisadas, evidenciando estabilidade estatística do exame ao longo do período considerado.

As análises de correlação entre as áreas de conhecimento mostraram relações positivas entre as notas, com destaque para a forte correlação entre Linguagens e Ciências Humanas, enquanto combinações como Ciências da Natureza e Redação apresentaram menor associação linear. Além disso, observou-se comportamento bimodal nas distribuições das notas de Matemática e Redação, o que sugere heterogeneidade no desempenho dos participantes e possíveis influências dos critérios avaliativos e do perfil dos estudantes.

O modelo de regressão linear múltipla aplicado aos dados evidenciou que variáveis relacionadas ao contexto educacional, como a dependência administrativa da escola e a localização geográfica, exercem influência significativa sobre a nota final dos candidatos. Embora o modelo apresente limitações — como a exclusão de participantes com dados faltantes e a não inclusão de todas as variáveis potencialmente relevantes —, os resultados reforçam a importância de fatores estruturais no desempenho acadêmico.

Por fim, a análise espacial revelou a existência de autocorrelação espacial positiva nas notas médias municipais, indicando que municípios com melhor desempenho tendem a estar próximos geograficamente de outros com características semelhantes. Esse resultado aponta para desigualdades regionais persistentes no desempenho educacional, ressaltando a necessidade de políticas públicas direcionadas.

De modo geral, este estudo demonstra o potencial da análise estatística aplicada aos dados do ENEM como ferramenta para compreender o desempenho educacional no Brasil, fornecendo subsídios relevantes para futuras investigações e para a formulação de estratégias voltadas à redução das desigualdades educacionais.

REFERÊNCIAS

Wasserman, L. (2003). *All of statistics: a concise course in statistical inference*. Springer.

J. D. SCALON (2024). *Análise de dados espaciais com aplicações em R*. Ed. UFLA.

```

# ANEXO: CÓDIGOS EM R PARA A ANALISE DOS DADOS
library(dplyr)
library(ggplot2)
library(ggpubr)
library(tidyr)

#Estudo dos resultados de 2024, 2023, 2022 e 2021:
dat1_2024 <- read.csv2("Dados_utilizados\\RESULTADOS_2024.csv")

dat1_2023 <- read.csv2("Dados_utilizados\\MICRODADOS_ENEM_2023.csv")

dat1_2022 <- read.csv2("Dados_utilizados\\MICRODADOS_ENEM_2022.csv")

# Função para criar nota final para cada ano:
cria_nota_final <- function(dat1) {

  # Transformando todas as notas em dado tipo double:
  dat1$NU_NOTA_CN <- as.double(dat1$NU_NOTA_CN) #nota de ciências da natureza
  dat1$NU_NOTA_CH <- as.double(dat1$NU_NOTA_CH) #nota de ciências humanas
  dat1$NU_NOTA_LC <- as.double(dat1$NU_NOTA_LC) #nota de linguagens e códigos
  dat1$NU_NOTA_MT <- as.double(dat1$NU_NOTA_MT) #nota de matemática
  dat1$NU_NOTA_REDACAO <- as.double(dat1$NU_NOTA_REDACAO) #nota da redação

  # Criar coluna com notas finais
  dat1 <- dat1 |>
    mutate(nota_final = rowMeans(across(c(NU_NOTA_CN,
                                           NU_NOTA_CH,
                                           NU_NOTA_LC,
                                           NU_NOTA_MT,
                                           NU_NOTA_REDACAO))))

  return(dat1)
}

dat1_2022 <- cria_nota_final(dat1_2022)
dat1_2023 <- cria_nota_final(dat1_2023)
dat1_2024 <- cria_nota_final(dat1_2024)

#####
# 1. Distribuição das notas: 2024 a 2022 concordam
#####

dat1 <- dat1_2024

g1 <- dat1 |>
ggplot( aes(x = nota_final)) +
geom_boxplot(fill = "lightblue") +
labs( title = "Boxplot das notas ENEM - 2024",
      x = "Notas",
      y = "") +
theme_minimal()

not_media <- mean(dat1$nota_final, na.rm = TRUE)
not_sd <- sd(dat1$nota_final, na.rm = TRUE)

g2 <- dat1 |>
ggplot( aes(x = nota_final)) +
  scale_color_manual(
    name = "Legenda",
    values = c("ajuste" = "black", "histograma" = "blue")) +
  geom_histogram(aes(y = after_stat(density), color = "histograma"), fill = "steelblue",
alpha = 0.7) +
  stat_function(aes(color = "ajuste"), fun = dnorm, args = list(mean = not_media, sd =
not_sd), linewidth = 0.8) +
  labs( title = "Distribuição de notas ENEM - 2024",
        x = "Notas",
        y = "Densidade de probabilidade") +
  theme_minimal()

```

```

#Qual distribuição melhor descreve essa distribuição?
#Talvez a distribuição normal, sim, o ajuste é muito bom!

not_norm <- (dat1$nota_final - not_media)/not_sd
vet_p <- seq(0.0001, 0.9999, 0.0001)
quan_norm <- qnorm(vet_p)
quan_dis_notas <- quantile(not_norm, probs = vet_p, na.rm = TRUE)

#calculo do coeficiente de determinação:
r2 <- 1-(sum((quan_dis_notas-quan_norm)**2)/sum((quan_dis_notas-mean(quan_dis_notas))**2)) ;
r2

r2_text <- sprintf("R² = %.5f", r2)

g3 <- ggplot(data.frame(quan_norm,quan_dis_notas), aes(x = quan_norm, y = quan_dis_notas)) +
  geom_line(aes(x = quan_norm, y = quan_norm, color = "esperado")) +
  geom_point(aes(x = quan_norm, y = quan_dis_notas, color = "dados")) +
  scale_color_manual(
    name = "Legenda",
    values = c("esperado" = "black", "dados" = "blue")) +
  labs( title = "Gráfico QQ-plot para as distribuições de nota ENEM-2024",
        subtitle = r2_text,
        x = "Quantis da normal padrão",
        y = "Quantis da amostra") +
  theme_minimal()

ggarrange(g1, g2, g3,
          ncol = 1, nrow = 3,
          legend = "right")

ggsave("Gráficos_gerados\\distribuição_2024.png", width = 8, height = 6, dpi = 300)

# Criar tabela com coeficientes de determinação das edições anteriores:
df_list <- list(
  dat1_2022,
  dat1_2023,
  dat1_2024
)
cof_r2 <- c()
for (i in 1:3) {
  dat1 <- data.frame(df_list[i]) #seleciona o ano de estudo

  # Transformando todas as notas em dado tipo double:
  dat1$NU_NOTA_CN <- as.double(dat1$NU_NOTA_CN) #nota de ciências da natureza
  dat1$NU_NOTA_CH <- as.double(dat1$NU_NOTA_CH) #nota de ciências humanas
  dat1$NU_NOTA_LC <- as.double(dat1$NU_NOTA_LC) #nota de linguagens e códigos
  dat1$NU_NOTA_MT <- as.double(dat1$NU_NOTA_MT) #nota de matemática
  dat1$NU_NOTA_REDACAO <- as.double(dat1$NU_NOTA_REDACAO) #nota da redação

  # Criar coluna com notas finais
  dat1 <- dat1 |>
    mutate(nota_final = rowMeans(across(c(NU_NOTA_CN,
                                          NU_NOTA_CH,
                                          NU_NOTA_LC,
                                          NU_NOTA_MT,
                                          NU_NOTA_REDACAO))))

  not_media <- mean(dat1$nota_final, na.rm = TRUE)
  not_sd <- sd(dat1$nota_final, na.rm = TRUE)

  not_norm <- (dat1$nota_final - not_media)/not_sd
  vet_p <- seq(0.0001, 0.9999, 0.0001)
  quan_norm <- qnorm(vet_p)

  quan_dis_notas <- quantile(not_norm, probs = vet_p, na.rm = TRUE)
  r2 <- 1-(sum((quan_dis_notas-quan_norm)**2)/sum((quan_dis_notas-mean(quan_dis_notas))**2))
; r2

```

```

    cof_r2 <- c(cof_r2, r2)
  }
  #Montar a tabela:
  pacman::p_load(gt)

  cof_r2_2 <- data.frame(Ano = c("2022","2023","2024"), R2 = cof_r2)

  cof_r2_2 |> gt()

#Notas por localização da escola (1-urbana , 2-rural)
name <- c("Urbana","Rural")
not_loc <- aggregate(nota_final ~ TP_LOCALIZACAO_ESC , data = dat1, mean)
y <- table(select(dat1,TP_LOCALIZACAO_ESC))
y <- y/sum(y)
not_loc <- mutate(not_loc, Proporção = y) ; not_loc

#Notas por dependencia administrativa:
not_dep <- aggregate(nota_final ~ TP_DEPENDENCIA_ADM_ESC , data = dat1, mean)
y <- table(select(dat1,TP_DEPENDENCIA_ADM_ESC))
y <- y/sum(y)
not_dep <- mutate(not_dep, Proporção = y) ; not_dep

#Notas por situação de funcionamento da escola:
#Todas as escolas estão em funcionamento em 2024. 2023 é diferente
not_fun <- aggregate(nota_final ~ TP_SIT_FUNC_ESC , data = dat1, mean)
y <- table(select(dat1,TP_SIT_FUNC_ESC))
y <- y/sum(y)
not_fun <- mutate(not_fun, Proporção = y) ; not_fun

#Proporções de situação da redação dos participantes: Não é interessante
est_redacao <- table(select(dat1,TP_STATUS_REDACAO))
est_redacao <- est_redacao/sum(est_redacao) ; est_redacao

#####
# 2. Calculo do coeficiente de correlação de pearson para todas as areas:
# 2024 e 2023 concordam, 2022 tem algo diferente
#####

library(GGally)

painel_disp <- function(data, mapping, ...) {
  ggplot(sample_frac(select(dat1, NU_NOTA_CN,
                           NU_NOTA_CH,
                           NU_NOTA_LC,
                           NU_NOTA_MT,
                           NU_NOTA_REDACAO), 0.01), mapping) +
    geom_point(alpha = 0.1, size = 0.1) +
    theme_bw()
}

painel_cor <- function(data, mapping, ...) {
  x <- eval_data_col(data, mapping$x)
  y <- eval_data_col(data, mapping$y)
  r <- cor(x, y, use = "pairwise.complete.obs")

  ggally_text(
    label = sprintf("r = %.4f", r),
    xP = 0.5, yP = 0.5, size = 5
  )
}

painel_dens <- function(data, mapping, ...) {
  ggplot(data, mapping) +
    geom_density(fill = "lightblue", alpha = 0.5) +
    theme_bw()
}

```

```

dat1 <- dat1_2022 #seleciona o ano em estudo

ggpairs(
  data = select(dat1, NU_NOTA_CN,
                NU_NOTA_CH,
                NU_NOTA_LC,
                NU_NOTA_MT,
                NU_NOTA_REDACAO),
  lower = list(continuous = painel_disp),
  upper = list(continuous = painel_cor),
  diag = list(continuous = painel_dens),
  columnLabels = c("Ciências da Natureza",
                  "Ciências Humanas",
                  "Linguagens e Códigos",
                  "Matemática",
                  "Redação"))

ggsave("Gráficos_gerados\\correlacao_por_areas_2022.png", width = 8, height = 6, dpi = 300)

#####
# 3. Análise linear multivariada
# dados de 2022 para criar o modelo e dados de 2023 para testá-lo
#####

#função para criar as variáveis categóricas a serem usadas no modelo e na verificação
prep_model <- function(dat1) {

  #retira os candidatos com notas finais com NA:
  dat1 <- dat1 |> filter(!is.na(nota_final))

  dat1 <- dat1 |> rename(estado_escola = SG_UF_ESC)
  dat1 <- dat1 |> rename(dependencia_adm = TP_DEPENDENCIA_ADM_ESC)
  dat1 <- dat1 |> rename(localizacao_escola = TP_LOCALIZACAO_ESC)
  dat1 <- dat1 |> rename(faixa_etaria = TP_FAIXA_ETARIA)
  dat1 <- dat1 |> rename(sexo = TP_SEXO)
  dat1 <- dat1 |> rename(cor_raca = TP_COR_RACA)
  dat1 <- dat1 |> rename(tipo_escola = TP_ESCOLA)
  dat1 <- dat1 |> rename(escolaridade_pai = Q001)
  dat1 <- dat1 |> rename(escolaridade_mae = Q002)
  dat1 <- dat1 |> rename(ocupacao_pai = Q003)
  dat1 <- dat1 |> rename(ocupacao_mae = Q004)
  dat1 <- dat1 |> rename(pessoas_na_residencia = Q005)
  dat1 <- dat1 |> rename(renda_familiar_mensal = Q006)
  dat1 <- dat1 |> rename(possui_computador = Q024)
  dat1 <- dat1 |> rename(possui_internet = Q025)

  # Transformar as variáveis explicativas em fator

  dat1$estado_escola <- as.factor(dat1$estado_escola)
  dat1$estado_escola <- relevel(dat1$estado_escola, ref = "SP")
  dat1$estado_escola[dat1$estado_escola == ""] <- NA

  dat1$pessoas_na_residencia <- as.factor(dat1$pessoas_na_residencia)

  dat1$dependencia_adm <- as.factor(dat1$dependencia_adm)
  levels(dat1$dependencia_adm) <- c(":" Federal", ":" Estadual", ":" Municipal", ":" Privada")
  dat1$dependencia_adm <- relevel(dat1$dependencia_adm, ref = ":" Privada")

  dat1$localizacao_escola <- as.factor(dat1$localizacao_escola)
  levels(dat1$localizacao_escola) <- c(":" Urbana", ":" Rural")

  dat1$faixa_etaria <- as.factor(dat1$faixa_etaria)
  levels(dat1$faixa_etaria) <- c(":" Menor de 17 anos",
                                ":" 17 anos",
                                ":" 18 anos",
                                ":" 19 anos",
                                ":" 20 anos",
                                ":" 21 anos",

```

```

": 22 anos",
": 23 anos",
": 24 anos",
": 25 anos",
": Entre 26 e 30 anos",
": Entre 31 e 35 anos",
": Entre 36 e 40 anos",
": Entre 41 e 45 anos",
": Entre 46 e 50 anos",
": Entre 51 e 55 anos",
": Entre 56 e 60 anos",
": Entre 61 e 65 anos",
": Entre 66 e 70 anos",
": Maior de 70 anos")

```

```

dat1$sexo <- as.factor(dat1$sexo)
levels(dat1$sexo) <- c(":", Feminino", ": Masculino")

```

```

dat1$cor_raca <- as.factor(dat1$cor_raca)
dat1$cor_raca[dat1$cor_raca == "6"] <- NA
levels(dat1$cor_raca) <- c(":", Não declarado",
": Branca",
": Preta",
": Parda",
": Amarela",
": Indígena")

```

```

dat1$tipo_escola <- as.factor(dat1$tipo_escola)
dat1$tipo_escola[dat1$tipo_escola == "1"] <- NA
levels(dat1$tipo_escola) <- c(":", Não Respondeu",
": Pública",
": Privada")

```

```

dat1$renda_familiar_mensal <- as.factor(dat1$renda_familiar_mensal)
levels(dat1$renda_familiar_mensal) <- c(":", Nenhuma Renda",
": Até R$ 1.212,00",
": De R$ 1.212,01 até R$ 1.818,00.",
": De R$ 1.818,01 até R$ 2.424,00.",
": De R$ 2.424,01 até R$ 3.030,00.",
": De R$ 3.030,01 até R$ 3.636,00.",
": De R$ 3.636,01 até R$ 4.848,00.",
": De R$ 4.848,01 até R$ 6.060,00.",
": De R$ 6.060,01 até R$ 7.272,00.",
": De R$ 7.272,01 até R$ 8.484,00.",
": De R$ 8.484,01 até R$ 9.696,00.",
": De R$ 9.696,01 até R$ 10.908,00.",
": De R$ 10.908,01 até R$ 12.120,00.",
": De R$ 12.120,01 até R$ 14.544,00.",
": De R$ 14.544,01 até R$ 18.180,00.",
": De R$ 18.180,01 até R$ 24.240,00.",
": Acima de R$ 24.240,00.")

```

```

#dat1$renda_familiar_mensal <- relevel(dat1$renda_familiar_mensal, ref = "Nenhuma Renda")

```

```

dat1$escolaridade_pai <- as.factor(dat1$escolaridade_pai)
dat1$escolaridade_pai[dat1$escolaridade_pai == "H"] <- NA

```

```

dat1$escolaridade_mae <- as.factor(dat1$escolaridade_mae)
dat1$escolaridade_mae[dat1$escolaridade_mae == "H"] <- NA

```

```

dat1$ocupacao_pai <- as.factor(dat1$ocupacao_pai)
dat1$ocupacao_pai[dat1$ocupacao_pai == "F"] <- NA

```

```

dat1$ocupacao_mae <- as.factor(dat1$ocupacao_mae)
dat1$ocupacao_mae[dat1$ocupacao_mae == "F"] <- NA

```

```

dat1$possui_computador <- as.factor(dat1$possui_computador)
levels(dat1$possui_computador) <- c(":", Não.",
": Sim, um.",
": Sim, dois.",

```

```

        ": Sim, três.",
        ": Sim, quatro ou mais.")

dat1$possui_internet <- as.factor(dat1$possui_internet)
levels(dat1$possui_internet) <- c(": Não.", ": Sim.")

return(dat1)
}

# Modelo de regressão linear multivariada aplicado em 2022:
dat1_2022 <- prep_model(dat1_2022)

modelo_2022 = lm(nota_final ~ estado_escola +
  pessoas_na_residencia +
  dependencia_adm +
  localizacao_escola +
  faixa_etaria +
  sexo +
  cor_raca +
  tipo_escola +
  renda_familiar_mensal +
  escolaridade_pai +
  escolaridade_mae +
  ocupacao_pai +
  ocupacao_mae +
  possui_computador +
  possui_internet, data = dat1_2022)

summary(modelo_2022)

#analise com a função ANOVA:
anova(modelo_2022)
#O desempenho dos alunos é fortemente influenciado por fatores estruturais da escola
(dependência administrativa, tipo, localização) e fatores socioeconômicos (renda, escolaridade
dos pais, raça). Variáveis individuais como sexo têm efeito menor, mas ainda significativo.

# stepAIC: escolhe as variaveis mais relevantes automaticamente:
library(MASS)
stepAIC(modelo_2022, direction = "both")

#VIP: importância de variáveis
install.packages("vip")
library(vip)
vip(modelo_2022)

#usaremos o modelo de regressão de 2022 para tentar descrever os resultados de 2023:

# prepara os dados de 2023 para serem inseridos no modelo:
dat1_2023 <- prep_model(dat1_2023)

# executa a previsão para o novo ano:
# problemas com os novos níveis:
nota_pred <- predict(modelo_2022, newdata = dat1_2023)

# avalia se o modelo é consistente:
mse <- mean((dat1_2023$nota_final - nota_pred)^2, na.rm = TRUE)
ss_res <- sum((dat1_2023$nota_final - nota_pred)^2, na.rm = TRUE)
ss_tot <- sum((dat1_2023$nota_final - mean(dat1_2023$nota_final, na.rm = TRUE))^2, na.rm =
TRUE)
r2 <- 1 - ss_res/ss_tot ; r2
np <- sum(!is.na(nota_pred))/(length(nota_pred)) ; np

#####
# Distribuição das notas tem relação com o tamanho da escola?
# 2024: SÓ seria aplicar a essa edição
# 2023: não tem o id da escola
# 2022: idem a 2023

```

```
#####
#Dados do catalogo das escolas:
dat2 <- read.csv("Dados_utilizados\\Análise - Tabela da lista das escolas - Detalhado.csv")

not_media_por_escolas <- aggregate(nota_final ~ CO_ESCOLA, data = dat1, mean)

dat3 <- data.frame(CO_ESCOLA = dat2$Código.INEP, porte_esc = dat2$Porte.da.Escola)

# Anexar o tamanho das escolas:
dat4 <- left_join(not_media_por_escolas, dat3)

#mas as escolas com menos de 10 participantes tem o seu id substituido por uma mascara?
#o que pode ser inferido de uma escola com menos de 10 participantes?
#12% das escolas não foram encontradas nessa base de dados!
#pode ser que a base de dados do censo das escola esteja incompleta

rot <- c(
  "Dados faltantes",
  "Até 50 matrículas de escolarização",
  "Entre 51 e 200 matrículas de escolarização",
  "Entre 201 e 500 matrículas de escolarização",
  "Entre 501 e 1000 matrículas de escolarização",
  "Mais de 1000 matrículas de escolarização"
)

glob <- list(dat4[is.na(dat4$porte_esc),],
  dat4[dat4$porte_esc == "Até 50 matrículas de escolarização",],
  dat4[dat4$porte_esc == "Entre 51 e 200 matrículas de escolarização",],
  dat4[dat4$porte_esc == "Entre 201 e 500 matrículas de escolarização",],
  dat4[dat4$porte_esc == "Entre 501 e 1000 matrículas de escolarização",],
  dat4[dat4$porte_esc == "Mais de 1000 matrículas de escolarização",])

max_len <- max(length(glob[1:6]))

df <- data.frame(
  A = c(a, rep(NA, max_len - length(a))),
)

for (i in 1:6) {
  data.frame(glob[i]) |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +
  coord_flip()
}

plot1 <-
  dat4[dat4$porte_esc == "Mais de 1000 matrículas de escolarização",] |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +
  coord_flip() +
  ylab("Mais de 1000 alunos") +
  xlab("")

plot2 <-
  dat4[dat4$porte_esc == "Entre 501 e 1000 matrículas de escolarização",] |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +

```



```

coord_flip() +
ylab("entre 501 e 1000 alunos") +
xlab("")

plot3 <-
  dat4[dat4$porte_esc == "Entre 201 e 500 matrículas de escolarização",] |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +
  coord_flip() +
  ylab("entre 201 e 500 alunos") +
  xlab("")

plot4 <-
  dat4[dat4$porte_esc == "Entre 51 e 200 matrículas de escolarização",] |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +
  coord_flip() +
  ylab("entre 51 e 200 alunos") +
  xlab("")

plot5 <-
  dat4[dat4$porte_esc == "Até 50 matrículas de escolarização",] |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +
  coord_flip() +
  ylab("até 50 alunos") +
  xlab("")

plot6 <-
  dat4[is.na(dat4$porte_esc),] |>
  ggplot( aes(x = nota_final)) +
  geom_boxplot() +
  coord_flip() +
  ylab("Dados faltantes") +
  xlab("")

ggarrange(plot6, plot5, plot4, plot3, plot2, plot1,
  ncol = 6, nrow = 1,
  common.legend = TRUE,
  legend = "none")

#Verifica o peso que cada categoria de escola tem no exame
table(dat4$porte_esc)/length(dat4$porte_esc)

#####
#      Distribuição das notas geograficamente:
#####

if (!require("pacman")) install.packages("pacman")
pacman::p_load(geobr, sf, ggplot2, dplyr)
library(sf)
library(spdep)

dat1 <- dat1_2022 #seleciona o ano da análise

#criar data frame de cidade em função da media.
med_muni <- aggregate(nota_final ~ CO_MUNICIPIO_ESC , data = dat1, mean)
colnames(med_muni)[1] <- "code_muni"

# Ler todos os municipios em 2022 (Ano de Censo)
municipios <- read_municipality(code_muni = "all", year = 2022, showProgress = FALSE)

```

```

mapa <- municipios %>%
  left_join(med_muni, by = "code_muni")
# municipios sem nota são substituídos pela mediana nacional
mapa$nota_final[is.na(mapa$nota_final)] <- median(mapa$nota_final, na.rm = TRUE)

mapa <- st_make_valid(mapa) |> st_cast("MULTIPOLYGON")

# 1) Criar vizinhança (contiguidade)
nb <- poly2nb(mapa)

# 2) Criar matriz de pesos espaciais
lw <- nb2listw(nb, style = "W", zero.policy = TRUE)

# 3) Teste de Moran
moran.test(mapa$nota_final, lw, zero.policy = TRUE)

#2024:
moran_text <- sprintf("Moran I statistic = %.5f , valor-p < 2.2e-16", 4.531940e-01)

#2023:
moran_text <- sprintf("Moran I statistic = %.5f , valor-p < 2.2e-16", 3.153219e-01)

#2022:
moran_text <- sprintf("Moran I statistic = %.5f , valor-p < 2.2e-16", 3.346726e-01)

ggplot(mapa) +
  geom_sf(aes(fill = nota_final), color = NA) +
  scale_fill_viridis_c(option = "magma", na.value = "grey90") +
  theme_minimal() +
  labs(
    fill = "Nota média",
    title = "Nota média do enem 2022 por municipio brasileiro",
    subtitle = moran_text
  )

ggsave("Gráficos_gerados\\distribuição_mapa_2022.png", width = 8, height = 6, dpi = 300)

```